


# CLASSIFICATION NON-SUPERVISÉE

Romain Thoreau, Vincent Guigue  
[romain.thoreau@agroparistech.fr](mailto:romain.thoreau@agroparistech.fr)

# Catégorisation automatique de données de science participative

Un consortium d'organismes de recherche (CIRAD, Inria, INRAE et IRD) a développé un projet de sciences participatives Pl@ntNet<sup>1</sup> pour **cartographier la distribution des plantes dans le monde**.

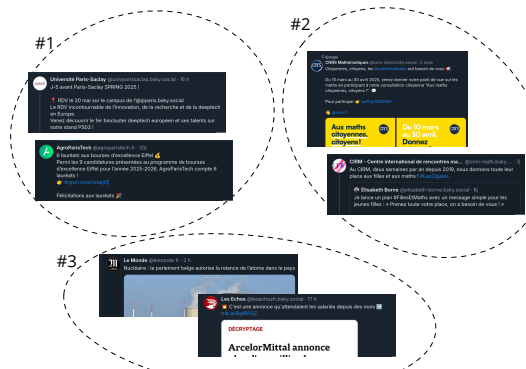
L'équipe souhaite **regrouper automatiquement les plantes qui se ressemblent sans aucun a priori** sur la taxonomie des espèces photographiées par les utilisateurs.



<sup>1</sup><https://plantnet.org/>

# Classification automatique de contenu sur les réseaux sociaux

Une équipe de recherche en apprentissage statistique et en sciences sociales utilise les algorithmes présentés dans *An evaluation of document clustering and topic modelling in two online social networks: Twitter and Reddit*, [Curiskis et al., 2020], pour classer les posts du réseau social Bluesky<sup>2</sup>.



<sup>2</sup><https://bsky.app/>

# Détection automatique du dépérissement des hêtres

Une équipe de recherche étudie la **cartographie automatique du dépérissement des hêtres** dû aux épisodes de sécheresse.




Figure 1: Photo-interprétation du dépérissement des hêtres dû à la sécheresse à partir d'une image multi-spectrale acquise par drone dans le Doubs. Source : IGN, ONF, Bélouard T. et al.





Figure 2: Réflectance de deux pixels de l'image multispectrale.



# Classification supervisée VS non supervisée

## Classification supervisée


On modélise la relation entre une variable qualitative  $Y$  et une variable  $X \in \mathbb{R}^p$  à partir d'observations  $\{(x_1, y_1), \dots, (x_n, y_n)\}$ .



# Classification supervisée VS non supervisée


## Classification supervisée

On modélise la relation entre une variable qualitative  $Y$  et une variable  $X \in \mathbb{R}^p$  à partir d'observations  $\{(x_1, y_1), \dots, (x_n, y_n)\}$ .



## Classification non supervisée

On groupe / partitionne les observations  $\{x_1, \dots, x_n\}$  en  $K$  classes / partitions.



# Qu'est-ce qu'une partition des données ?

On désigne par  $\mathcal{C} = \{C_1, \dots, C_K\}$  une partition des observations  $\{1, \dots, n\}$  en  $K$  classes :

- $\bigcup_{i=1}^K C_k = \{1, \dots, n\}$ ,  $C_i \cap C_j = \emptyset$  pour tout  $i \neq j$ , et  $C_k \neq \emptyset$  pour tout  $k$ .
- l'échantillon  $i$  appartient à la classe  $k$  si  $i \in C_k$ .




Figure 3: Exemple de partition des données IRIS


# ALGORITHME DES K-MOYENNES



# Comment définir une bonne partition ?

Intuitivement, une bonne partition regroupe des échantillons *similaires* dans une même classe :

- on utilise une distance  $d : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$  (e.g. la distance euclidienne) pour mesurer la similarité entre deux échantillons,




# Comment définir une bonne partition ?

Intuitivement, une bonne partition regroupe des échantillons *similaires* dans une même classe :

- on utilise une distance  $d : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$  (e.g. la distance euclidienne) pour mesurer la similarité entre deux échantillons,
- on minimise la variabilité / hétérogénéité / inertie intra-classe

$$I_W \stackrel{\text{def}}{=} \sum_{k=1}^K \sum_{i \in C_k} d(x_i, \bar{x}_k)^2$$

où  $\bar{x}_k = \frac{1}{|C_k|} \sum_{i \in C_k} x_i$  pour tout  $k \in (1, \dots, K)$ .





# La distance euclidienne : une bonne mesure de similarité ? (1/2)

Exemple 1 On souhaite partitionner  $n$  individus selon leur taille (m) et leur poids (kg).

- Est-ce qu'une différence d'1kg entre deux individus est aussi significative qu'une différence d'1m ?
- Est-ce qu'un partitionnement sur la taille en (m) et le poids en (kg) est identique à un partitionnement sur la taille en (cm) et le poids en (kg) ?



# La distance euclidienne : une bonne mesure de similarité ? (1/2)

Exemple 1 On souhaite partitionner  $n$  individus selon leur taille (m) et leur poids (kg).

- Est-ce qu'une différence d'1kg entre deux individus est aussi significative qu'une différence d'1m ?
  - Est-ce qu'un partitionnement sur la taille en (m) et le poids en (kg) est identique à un partitionnement sur la taille en (cm) et le poids en (kg) ?
- **centrer et réduire les données.**

# La distance euclidienne : une bonne mesure de similarité ? (2/2)

Exemple 2 On souhaite partitionner  $n$  images de plantes :



— Est-ce que la distance mesurée pixel à pixel est une bonne mesure de similarité ?

# La distance euclidienne : une bonne mesure de similarité ? (2/2)

Exemple 2 On souhaite partitionner  $n$  images de plantes :



— Est-ce que la distance mesurée pixel à pixel est une bonne mesure de similarité ?


—> **extraire préalablement des caractéristiques utiles à la classification (forme, texture...)**

# Inertie intra-classe VS inertie inter-classe

*Est-ce suffisant de minimiser l'inertie intra-classe ? Ne devrions-nous pas également maximiser l'inertie inter-classe*

$$I_B \stackrel{\text{def}}{=} \sum_{k=1}^K |C_k| d(\bar{x}_k, \bar{x})^2$$

où  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$  ?




# Inertie intra-classe VS inertie inter-classe

*Est-ce suffisant de minimiser l'inertie intra-classe ? Ne devrions-nous pas également maximiser l'inertie inter-classe*

$$I_B \stackrel{\text{def}}{=} \sum_{k=1}^K |C_k| d(\bar{x}_k, \bar{x})^2$$

où  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$  ?



Minimiser l'inertie intra-classe est équivalent à maximiser l'inertie inter-classe

$$\min_{(C_1, \dots, C_K)} \sum_{k=1}^K \sum_{i \in C_k} d(x_i, \bar{x}_k)^2 = \max_{(C_1, \dots, C_K)} \sum_{k=1}^K |C_k| d(\bar{x}_k, \bar{x})^2 \quad (1)$$





# Optimisation de la partition

## Problème de classification non supervisée

$$\mathcal{C}^* = \arg \min_{(C_1, \dots, C_K)} \sum_{k=1}^K \sum_{i \in C_k} d(x_i, \bar{x}_k)^2 \quad (2)$$

Il y a  $K^n$  partitions possibles (incluant des partitions qui comprennent des classes vides), soit 10 milliards de partitions possibles pour seulement  $K = 10$  et  $n = 10$  !

# Algorithme des K-moyennes


## Algorithme des K-moyennes

▷ On fixe le nombre de classes

$K \leftarrow 3$

▷ Initialisation aléatoires des centres des classes

$c_1, c_2, c_3 \leftarrow \text{Initialisation}(K)$



# Algorithme des K-moyennes

## Algorithme des K-moyennes

▷ On fixe le nombre de classes

$K \leftarrow 3$

▷ Initialisation aléatoires des centres des classes

$c_1, c_2, c_3 \leftarrow \text{Initialisation}(K)$

**tant que** les centres  $c_i$  "changent"

**faire**

▷ Attribution des classes


$z_i \leftarrow \arg \min_k d(x_i, c_k)$

▷ Mise à jour des centres

$c_k \leftarrow \frac{1}{\sum_{i=1}^n \gamma_{ik}} \sum_{i=1}^n \gamma_{ik} x_i$

**fin tant que**

où  $\gamma_{ik} = \begin{cases} 1 & \text{si la donnée } i \text{ appartient au cluster } k \\ 0 & \text{sinon} \end{cases}$



# Algorithme des K-moyennes

## Algorithme des K-moyennes

▷ On fixe le nombre de classes

$K \leftarrow 3$

▷ Initialisation aléatoires des centres des classes

$c_1, c_2, c_3 \leftarrow \text{Initialisation}(K)$

**tant que** les centres  $c_i$  "changent"

**faire**

▷ Attribution des classes


$z_i \leftarrow \arg \min_k d(x_i, c_k)$

▷ Mise à jour des centres

$c_k \leftarrow \frac{1}{\sum_{i=1}^n \gamma_{ik}} \sum_{i=1}^n \gamma_{ik} x_i$

**fin tant que**

où  $\gamma_{ik} = \begin{cases} 1 & \text{si la donnée } i \text{ appartient au cluster } k \\ 0 & \text{sinon} \end{cases}$





# Algorithme des K-moyennes

## Algorithme des K-moyennes

▷ On fixe le nombre de classes

$K \leftarrow 3$

▷ Initialisation aléatoires des centres des classes

$c_1, c_2, c_3 \leftarrow \text{Initialisation}(K)$

**tant que** les centres  $c_i$  "changent"

**faire**

▷ Attribution des classes


$z_i \leftarrow \arg \min_k d(x_i, c_k)$

▷ Mise à jour des centres

$$c_k \leftarrow \frac{1}{\sum_{i=1}^n \gamma_{ik}} \sum_{i=1}^n \gamma_{ik} x_i$$

**fin tant que**

où  $\gamma_{ik} = \begin{cases} 1 & \text{si la donnée } i \text{ appartient au cluster } k \\ 0 & \text{sinon} \end{cases}$





# Algorithme des K-moyennes

## Algorithme des K-moyennes

▷ On fixe le nombre de classes

$K \leftarrow 3$

▷ Initialisation aléatoires des centres des classes

$c_1, c_2, c_3 \leftarrow \text{Initialisation}(K)$

**tant que** les centres  $c_i$  "changent"

**faire**

▷ Attribution des classes


$z_i \leftarrow \arg \min_k d(x_i, c_k)$

▷ Mise à jour des centres

$c_k \leftarrow \frac{1}{\sum_{i=1}^n \gamma_{ik}} \sum_{i=1}^n \gamma_{ik} x_i$

**fin tant que**

où  $\gamma_{ik} = \begin{cases} 1 & \text{si la donnée } i \text{ appartient au cluster } k \\ 0 & \text{sinon} \end{cases}$



# Algorithme des K-moyennes

## Algorithme des K-moyennes

▷ On fixe le nombre de classes

$K \leftarrow 3$

▷ Initialisation aléatoires des centres des classes

$c_1, c_2, c_3 \leftarrow \text{Initialisation}(K)$

**tant que** les centres  $c_i$  "changent"

**faire**

▷ Attribution des classes


$z_i \leftarrow \arg \min_k d(x_i, c_k)$

▷ Mise à jour des centres

$c_k \leftarrow \frac{1}{\sum_{i=1}^n \gamma_{ik}} \sum_{i=1}^n \gamma_{ik} x_i$

**fin tant que**

où  $\gamma_{ik} = \begin{cases} 1 & \text{si la donnée } i \text{ appartient au cluster } k \\ 0 & \text{sinon} \end{cases}$



# Algorithme des K-moyennes

## Algorithme des K-moyennes

▷ On fixe le nombre de classes

$K \leftarrow 3$

▷ Initialisation aléatoires des centres des classes

$c_1, c_2, c_3 \leftarrow \text{Initialisation}(K)$

**tant que** les centres  $c_i$  "changent"

**faire**

▷ Attribution des classes


$z_i \leftarrow \arg \min_k d(x_i, c_k)$

▷ Mise à jour des centres

$c_k \leftarrow \frac{1}{\sum_{i=1}^n \gamma_{ik}} \sum_{i=1}^n \gamma_{ik} x_i$

**fin tant que**


où  $\gamma_{ik} = \begin{cases} 1 & \text{si la donnée } i \text{ appartient au cluster } k \\ 0 & \text{sinon} \end{cases}$





# Robustesse à l'initialisation des centres


*La fonction de coût décroît à chaque mise à jour des classes et des centres. Cela étant dit, l'algorithme converge-t-il vers un minimum global ?*




(a)  $t = 0$

# Robustesse à l'initialisation des centres

*La fonction de coût décroît à chaque mise à jour des classes et des centres. Cela étant dit, l'algorithme converge-t-il vers un minimum global ?*




(a)  $t = 0$



(b)  $t = 1$

# Robustesse à l'initialisation des centres


*La fonction de coût décroît à chaque mise à jour des classes et des centres. Cela étant dit, l'algorithme converge-t-il vers un minimum global ?*




(a)  $t = 2$

# Robustesse à l'initialisation des centres

*La fonction de coût décroît à chaque mise à jour des classes et des centres. Cela étant dit, l'algorithme converge-t-il vers un minimum global ?*




(a)  $t = 2$



(b)  $t = 3$

# Robustesse à l'initialisation des centres


*La fonction de coût décroît à chaque mise à jour des classes et des centres. Cela étant dit, l'algorithme converge-t-il vers un minimum global ?*




(a)  $t = 4$

# Robustesse à l'initialisation des centres

*La fonction de coût décroît à chaque mise à jour des classes et des centres. Cela étant dit, l'algorithme converge-t-il vers un minimum global ?*




(a)  $t = 4$




(b)  $t = 5$

# Robustesse à l'initialisation des centres



(a) "Mauvais" optimum local



(b) Optimum global



# Comment choisir le nombre de groupes ?

## Score Silhouette [Rousseeuw, 1987]

Pour un échantillon  $i$  appartenant à la classe  $j$ , le score Silhouette est

$$s_i \stackrel{\text{def}}{=} \frac{b_i - a_i}{\max(a_i, b_i)} \quad (3)$$

où  $a_i = \frac{1}{|C_j|} \sum_{l \in C_j} d(x_i, x_l)$  et  $b_i = \min_{C_k \neq C_j} \frac{1}{|C_k|} \sum_{l \in C_k} d(x_i, x_l)$ .







# Comment choisir le nombre de groupes ?

## Score Silhouette [Rousseeuw, 1987]

Pour un échantillon  $i$  appartenant à la classe  $j$ , le score Silhouette est

$$s_i \stackrel{\text{def}}{=} \frac{b_i - a_i}{\max(a_i, b_i)} \quad (3)$$

où  $a_i = \frac{1}{|C_j|} \sum_{l \in C_j} d(x_i, x_l)$  et  $b_i = \min_{C_k \neq C_j} \frac{1}{|C_k|} \sum_{l \in C_k} d(x_i, x_l)$ .



# CLASSIFICATION HIÉRARCHIQUE ASCENDANTE

# Classification hiérarchique ascendante

Classification qui agglomère les clusters deux par deux jusqu'à obtenir un seul cluster.




Figure 6: Dendrogramme de la classification hiérarchique

Figure 5: Classification hiérarchique ascendante sur les données IRIS

# DENSITY-BASED SPATIAL CLUSTERING OF APPLICA- TIONS WITH NOISE



# Density-Based Spatial Clustering of Applications with Noise

Classification de zones à forte densité (au moins `min_samples` points dans un voisinage de rayon  $\epsilon$ ).




Figure 7: DBSCAN sur les données IRIS. Les données en noir sont du bruit (des *outliers*). Les données représentées par des ronds sont les points centraux.



# Conclusion

- ▶ Il existe de nombreux algorithmes de classification non-supervisée.
- ▶ Ils sont plus ou moins pertinents en fonction de l'application et de la taille des données.
- ▶ La classification obtenue est très sensible aux hyper-paramètres. Comment les choisir ? On va voir cca en TP !



Bélouard, T., Gentils, M., and Jolly, A. (2021).  
Suivi des dégâts de scolytes par télédétection dans le nord-est de la france à l'initiative du ministère chargé des forêts.  
*Rendez-vous Techniques de l'ONF*, (69-70):28–36.



Curiskis, S. A., Drake, B., Osborn, T. R., and Kennedy, P. J. (2020).  
An evaluation of document clustering and topic modelling in two online social networks: Twitter and reddit.  
*Information Processing & Management*, 57(2):102034.



Rousseeuw, P. J. (1987).  
Silhouettes: a graphical aid to the interpretation and validation of cluster analysis.  
*Journal of computational and applied mathematics*, 20:53–65.