

TRAITEMENT AUTOMATIQUE DES IMAGES

Romain Thoreau, Vincent Guigue
romain.thoreau@agroparistech.fr


Mesurer la similarité de deux images ?



(a)



(b)



(c)

Figure 1: Credits (a, b) Dietrich Krieger, CC BY-SA 3.0, (c) I, Luc Viatour, CC BY 2.0.

Est-ce que $d(a, b)$ est inférieure à $d(a, c)$, où d désigne la distance euclidienne ?

DESCRIPTEURS D'IMAGES



Comment décrire / représenter des images ?

On souhaite représenter les images par des vecteurs de caractéristiques qui :

- décrivent la texture et les couleurs des images,
- décrivent les objets qu'elles contiennent,
- soient équivariants / invariants à certaines perturbations (e.g. translations des objets dans les images, variation de l'exposition).

► Les filtres de convolution sont omniprésents dans le traitement des images.



Comment décrire / représenter des images ?

On souhaite représenter les images par des vecteurs de caractéristiques qui :

- décrivent la texture et les couleurs des images,
- décrivent les objets qu'elles contiennent,
- soient équivariants / invariants à certaines perturbations (e.g. translations des objets dans les images, variation de l'exposition).

► **Les filtres de convolution sont omniprésents dans le traitement des images.**



Filtres de convolution




Figure 2: Illustration de l'opération de convolution

Détection de contours avec des filtres de Sobel




Figure 3: Réponses de différentes images à des filtres de Sobel

- Opération de convolution équivariante aux translations des objets dans l'image.

Détection de contours et de textures avec des filtres de Gabor




Figure 4: Réponses de différentes images à des filtres de Gabor

► Opération de convolution équivariante aux translations des objets dans l'image.

Histogramme de Gradients Orientés

La méthode de l'histogramme de gradients orientés :

- Calcule les gradients de l'image,
- Divise l'image en cellules,
- Calcule pour chaque cellule la distribution des gradients selon leur orientation.




Figure 5: Exemple d'histogramme de gradients orientés

► On obtient un vecteur de taille $n_{\text{cellules}} \times n_{\text{orientations}}$ pour décrire l'image.

BAGS OF VISUAL WORDS

Bags of visual words

Principe des Bags of visual words Description des images par un ensemble (dictionnaire / *bag*) d'éléments visuels de base (*visual words*), inspirée du traitement du langage naturel.




Figure 6: Exemple où les *visual words* sont calculés à partir de petits patches extraits des images de la base de données.

► De manière générale, les *visual words* sont calculés à partir de caractéristiques locales des images (e.g. histogramme des gradients).

Quantification des *visual words* pour obtenir un vocabulaire

Pour obtenir un vocabulaire d'une taille *raisonnable* (?), on utilise un algorithme de clustering (e.g. K-moyennes) pour partitionner les *visual words*.




Figure 7: Illustration d'une représentation d'une image par un *bag of visual words*. Les *codewords* sont les centres calculés par l'algorithme de clustering. Source: C. Schmid¹

► Ces descripteurs peuvent, par exemple, être utilisés par des modèles de classification.

¹https://www.ens-lyon.fr/LIP/Arenaire/ERVision/bof_classification_winter.pdf

Résultats expérimentaux pour des tâches de classification



(a) Images correctement classées.



Books- misclassified into faces, faces, buildings



Buildings- misclassified into faces, trees, trees



Cars- misclassified into buildings, phones, phones

(b) Confusions.

Figure 8: Résultats de classification à partir de *bags of visual words*. Source: C. Schmid²

²https://www.ens-lyon.fr/LIP/Arenaire/ERVision/bof_classification_winter.pdf

RÉSEAUX DE NEURONES À CONVOLUTION



Un changement de paradigme pour la reconnaissance des formes

- Les descripteurs d'images utilisent des filtres de convolution pour mettre en exergue des contours et des formes.

Les noyaux de convolution des filtres de Gabor, par exemple, sont définis selon par une fréquence et une orientation.

- Les réseaux de neurones à convolution sont utilisés dans un paradigme *end-to-end* : l'extraction de caractéristiques et l'apprentissage du modèle de classification sont conjoints.

Un changement de paradigme pour la reconnaissance des formes

- Les descripteurs d'images utilisent des filtres de convolution pour mettre en exergue des contours et des formes.

Les noyaux de convolution des filtres de Gabor, par exemple, sont définis selon par une fréquence et une orientation.

- Les réseaux de neurones à convolution sont utilisés dans un paradigme *end-to-end* : l'extraction de caractéristiques et l'apprentissage du modèle de classification sont conjoints.




Figure 9: Example of a network with many convolutional layers. Source: <https://au.mathworks.com/discovery/convolutional-neural-network.html>

Exemple : le modèle convolutif AlexNet




Figure 10: Noyaux de convolution de la première couche du modèle AlexNet




Figure 11: Réponses de l'image d'Iris aux filtres de la première couche d'AlexNet.

- Les filtres de la première couche du modèle ressemblent à des filtres de Gabor !
- Les filtres des couches plus *profondes*³ permettent de détecter des formes / objets plus complexes (e.g. une oreille, des yeux → un visage, des roues, une vitre → une voiture...).

³La visualisation des filtres des couches plus profondes est moins informative : pourquoi ?

Exemple : le modèle convolutif AlexNet




Figure 10: Noyaux de convolution de la première couche du modèle AlexNet




Figure 11: Réponses de l'image d'Iris aux filtres de la première couche d'AlexNet.

- Les filtres de la première couche du modèle ressemblent à des filtres de Gabor !
- Les filtres des couches plus *profondes*³ permettent de détecter des formes / objets plus complexes (e.g. une oreille, des yeux → un visage, des roues, une vitre → une voiture...).

³La visualisation des filtres des couches plus profondes est moins informative : pourquoi ?

Exemple : le modèle convolutif AlexNet




Figure 10: Noyaux de convolution de la première couche du modèle AlexNet




Figure 11: Réponses de l'image d'Iris aux filtres de la première couche d'AlexNet.

- Les filtres de la première couche du modèle ressemblent à des filtres de Gabor !
- Les filtres des couches plus *profondes*³ permettent de détecter des formes / objets plus complexes (e.g. une oreille, des yeux → un visage, des roues, une vitre → une voiture...).

³La visualisation des filtres des couches plus profondes est moins informative : pourquoi ?

Résultats expérimentaux sur des images complexes




Figure 4: **(Left)** Eight ILSVRC-2010 test images and the five labels considered most probable by our model. The correct label is written under each image, and the probability assigned to the correct label is also shown with a red bar (if it happens to be in the top 5). **(Right)** Five ILSVRC-2010 test images in the first column. The remaining columns show the six training images that produce feature vectors in the last hidden layer with the smallest Euclidean distance from the feature vector for the test image.

► En 2012, AlexNet gagne la compétition ImageNet⁴ et démontre pour la première fois la capacité des CNNs sur des jeux de données complexes.

⁴Avec un gain substantiel par rapport au second meilleur résultat.



Utiliser un CNN dans vos projets

```
https://github.com/vguigue/ML-2A/blob/main/B-MachineLearning/  
notebooks/pytorch\_models.ipynb
```

